



华南理工大学

South China University of Technology

《机器学习》课程实验报告

学 院 软件学院

专 业 软件工程

组 员 张梓佳

学 号 201530613726

邮 箱 969035716@qq.com

指导教师 吴庆耀

提交日期 2017 年 12 月 15 日

1. 实验题目: 逻辑回归、线性分类与随机梯度下降

2. 实验时间: 2017 年 月 日

3. 报告人: 张梓佳

4. 实验目的: 对比理解梯度下降和随机梯度下降的区别与联系。

对比理解逻辑回归和线性分类的区别与联系。

进一步理解 SVM 的原理并在较大数据上实践。

5. 数据集以及数据分析: 在本次实验的两次分实验中, 均使用 LIBSVM Data 的 a9a.txt 以及 a9a_testing.txt 文件

6. 实验步骤:

逻辑回归与随机梯度下降

1. 读取实验训练集和验证集。
2. 逻辑回归模型参数初始化, 可以考虑全零初始化, 随机初始化或者正态分布初始化。
3. 选择 Loss 函数及对其求导, 过程详见课件 ppt。
4. 求得部分样本对 Loss 函数的梯度。
5. 使用不同的优化方法更新模型参数 (NAG, RMSProp, AdaDelta 和 Adam)。
6. 选择合适的阈值, 将验证集中计算结果大于阈值的标记为正类, 反之为负类。在验证集上测试并得到不同优化方法的 Loss 函数值, 和。
7. 重复步骤 4-6 若干次, 画出, 和随迭代次数的变化图。

线性分类与随机梯度下降

1. 读取实验训练集和验证集。
2. 支持向量机模型参数初始化, 可以考虑全零初始化, 随机初始

化或者正态分布初始化。

3. 选择 Loss 函数及对其求导，过程详见课件 ppt。
4. 求得部分样本对 Loss 函数的梯度。
5. 使用不同的优化方法更新模型参数（NAG，RMSProp，AdaDelta 和 Adam）。
6. 选择合适的阈值，将验证集中计算结果大于阈值的标记为正类，反之为负类。在验证集上测试并得到不同优化方法的 Loss 函数值， J_{train} 和 J_{val} 。
7. 重复步骤 4-6 若干次，画出 J_{train} ， J_{val} 和随迭代次数的变化图。

8. 代码内容:

逻辑回归：（暂时只实现 NAG 方法的逻辑回归，只取关键部分）

```
#初始化参数
w=np.zeros((X_train.shape[1], 1))
LAMDA=1
GAMA=0.9
learning_rate=0.1 #定义学习率
num=200
iter_number=100 #定义迭代次数
threshold=0.5
shape1=range(0,X_train.shape[0])

#实现随机取样
def select_function(X, Y, n):
    random_num=random.sample(shape1, n)
    X_random=np.ones((0, X.shape[1]))
    Y_random=np.ones((0, Y.shape[1]))

    for i in random_num:
        X_random = np.r_[X_random, X[i].reshape(1, X.shape[1])]
        Y_random= np.r_[Y_random, Y[i].reshape(1, Y.shape[1])]
    return X_random, Y_random
```

```

def NAG(X, Y, w):
    w1 = w - GAMA * vt1
    loss_gradient=np.zeros(w.shape)
    for i in range(0, Y.shape[0]):
        Xi = X[i].reshape(1, X.shape[1]).T
        Yi = Y[i][0]
        loss_gradient = loss_gradient+ Yi / (1 + math.exp(Yi * np.dot(w1.T,
Xi)[0][0])) * Xi
    gradient=( LAMDA * w1 ) - 1 / num * loss_gradient
    vt = GAMA * vt1 + learning_rate * gradient
    w = w - vt
    return w

```

```

NAG_loss_list = []
for i in range(0, iter_number):
    vt1=np.zeros(w.shape)
    x_select, y_select=select_function(X_train, Y_train, num)
    w = NAG(x_select, y_select, w)
    loss_sum=0
    for i in range(0, Y_test.shape[0]):
        Xi = X_test[i].reshape(1, X_test.shape[1]).T
        Yi = Y_test[i][0]
        loss_sum += math.log(1 + math.exp(-Yi * np.dot(w.T, Xi)[0][0]))

    NAG_test_loss = LAMDA/2 * np.dot(w.T, w)[0][0] + 1/X_test.shape[0]
* loss_sum
    NAG_loss_list.append(NAG_test_loss)

```

线性分类（暂时只实现 NAG 方法的线性分类，只取关键部分）

#随机采样函数

```

def select_function(X, Y, n):
    random_num=random.sample(shape1, n)
    X_random=np.ones((0, X.shape[1]))
    Y_random=np.ones((0, Y.shape[1]))

    for i in random_num:
        X_random = np.r_[X_random, X[i].reshape(1, X.shape[1])]
        Y_random= np.r_[Y_random, Y[i].reshape(1, Y.shape[1])]
    return X_random, Y_random

```

```

def NAG(X, Y, w):

```

```

w = w - GAMA * vt1
for i in range(0, num):
    Xi = X[i].reshape(1, X.shape[1]).T
    Yi = Y[i][0]

    loss_gradient=np.zeros(w.shape)
    if(1-Yi*np.dot(w.T, Xi)[0][0])>=0:
        loss_gradient += -Yi*Xi

    gradient = w + C * loss_gradient
    vt = GAMA * vt1 + learning_rate * gradient
    w = w - vt

return w

NAG_loss_list = []
for i in range(0, iter_number):
    vt1 = np.zeros(w.shape)
    x_train, y_train = select_function(X_train, Y_train, num)
    w = NAG(x_train, y_train, w)
    loss_sum = 0
    for i in range(0, Y_test.shape[0]):
        Xi = X_test[i].reshape(1, X_test.shape[1]).T
        Yi = Y_test[i][0]

        WT = 1 - Yi * np.dot(w.T, Xi)[0][0]
        if ( WT > 0):
            loss_sum += WT

    NAG_test_loss = 1/2 * np.dot(w.T, w)[0][0] + C * 1/Y_test.shape[0] *
    loss_sum
    NAG_loss_list.append(NAG_test_loss)

```

9. 模型参数的初始化方法:

全零初始化

9.选择的 loss 函数及其导数:

逻辑回归 loss 函数:

$$J(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \log(1 + e^{-y_i \cdot \mathbf{w}^\top \mathbf{x}_i}) + \frac{\lambda}{2} \|\mathbf{w}\|_2^2$$

导数：

线性分类 loss 函数：

$$\min_{\mathbf{w}, b} \frac{\|\mathbf{w}\|^2}{2} + C \sum_{i=1}^n \max(0, 1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b))$$

10. 实验结果和曲线图：（各种梯度下降方式分别填写此项）

（NAG 方法实现的逻辑回归）

超参数选择：

GAMA=0.9

预测结果（最佳结果）：

(NAG 的 w)

W=[[-5.64423145e-02]

[-3.28699281e-02]

[-1.45092027e-02]

[5.27135944e-03]

[-1.06964997e-02]

[-8.63949481e-02]

[-7.44478249e-03]

[7.08725119e-03]

[1.60033197e-03]

[-6.22613229e-03]

[-6.29363385e-03]

[-2.03252110e-04]

[-2.17066525e-04]

[-2.35476943e-02]

[-1.87679886e-02]


[-1.45092883e-02]

[-2.38747935e-02]
[-2.85468209e-02]
[7.28657767e-03]
[-3.97903669e-02]
[-1.21279083e-02]
[-5.00122246e-02]
[7.27202270e-03]
[-1.63699082e-03]
[-4.01176044e-03]
[-4.30860105e-03]
[-6.06571343e-03]
[-5.00350217e-03]
[7.81064090e-03]
[-1.59481436e-03]
[-8.03235077e-03]
[4.96299049e-03]
[-3.29117282e-03]
[-7.03411687e-04]
[-4.11274746e-02]
[-5.00122246e-02]
[-3.97903669e-02]
[-5.64875126e-03]
[2.73322317e-02]
[3.49303838e-02]
[-3.29237083e-02]
[-8.83817409e-02]
[-8.75437526e-03]
[-1.04149319e-02]
[-3.92597946e-03]
[2.23766419e-04]
[1.56997579e-03]
[-1.50532798e-02]
[-2.88405175e-02]
[-1.21393217e-02]
[1.59818056e-02]
[1.02481892e-02]
[-1.27565352e-02]
[-1.17098839e-02]
[-2.21285882e-02]
[-9.61346298e-03]
[-1.04461939e-02]
[-1.53086612e-03]
[-1.39651054e-03]
[-5.99765377e-05]

[4.58880633e-03]
[-4.48394685e-02]
[3.23166653e-02]
[-6.36755992e-02]
[-9.23918013e-03]
[-2.83978094e-02]
[-7.99248224e-02]
[-3.28122862e-03]
[-2.94903003e-03]
[-1.53552946e-03]
[-2.15559751e-02]
[-7.73445152e-02]
[-3.19020704e-02]
[-1.22944130e-01]
[1.36975440e-02]
[-1.14918375e-01]
[5.67178908e-03]
[-4.51331491e-02]
[-1.48225651e-02]
[-5.62124730e-02]
[2.23813863e-03]
[4.68346304e-03]
[-9.04736372e-02]
[-1.16575077e-04]
[-7.46952441e-04]
[-1.06522525e-03]
[-8.96997270e-04]
[-1.94609630e-04]
[-2.70827439e-04]
[5.75952684e-05]
[5.18233929e-04]
[2.23919600e-05]
[-7.92107856e-04]
[-4.42948293e-04]
[-1.21961511e-04]
[1.66710492e-05]
[-1.96598596e-04]
[-1.12012175e-03]
[-2.20438890e-04]
[-3.97587963e-04]
[-7.36147145e-04]
[-3.67615257e-05]
[-5.55689090e-03]
[-3.35815058e-04]


```
[ -2.94294998e-04]
[  2.21205691e-04]
[ -6.38266911e-04]
[ -3.13165044e-04]
[ -3.75356750e-04]
[  9.29185054e-05]
[ -5.03432833e-04]
[ -4.44671660e-04]
[ -4.43389892e-05]
[ -2.16689308e-04]
[ -4.21137685e-04]
[ -6.34039682e-06]
[ -1.17778674e-04]
[ -1.42637408e-04]
[ -1.01299456e-03]
[ -4.32297316e-05]
[ -2.56577086e-04]
[  1.19619227e-04]
[  0.00000000e+00]]
```

loss 曲线图：



11.实验结果分析:在逻辑回归的实验中, Loss_function 在最初迭代期间有较大的优化, 但是在迭代的后期优化的效果则逐渐不明显

12.对比逻辑回归和线性分类的异同点: 逻辑回归和线性回归的 NAG 方法实现 w 的优化是相同的 并且在最初均是全零初始化 v_t 和 w 相同的, 线性分类实现中也是将 w 和 b 合并为一起计算

13.实验总结: 在本次实验中, 主要讲 NAG 方法较好地理解和实现, 并应用于逻辑回归和线性分类中, 并且较于第一次实验优化了梯度下降方法, 实现了随机梯度下降方法。但是对于其他三种优化算法, 在代码实现上出现了多个暂时没有解决的 bug, 将在实验后逐步实现代码并优化之。